



IUT Lyon 1

NUMÉROBIS
rénovation

IUT Lyon 1 — Département Informatique
BUT Informatique — 2ème année
Année universitaire 2025-2026

RAPPORT DE STAGE

Constitution d'une base de données articles fournitures
par extraction automatisée de factures PDF

Stage effectué du 06 avril 2026 au 29 mai 2026

Rapport réalisé par :
Walid Babouri

Entreprise d'accueil : Numérobis Rénovation
117 Avenue Paul Marcellin, 69120 Vaulx-en-Velin

Tutrice enseignante : Isabelle Dautraix
Maître de stage : Christophe Gallifet

Fiche technique

Élément	Informations
Nom et prénom du stagiaire	Walid Babouri
Formation	BUT Informatique — 2 ^e année — Parcours AGED — IUT Lyon 1
Année universitaire	2025–2026
Entreprise d'accueil	Numérobis Rénovation
Adresse de l'entreprise	117 Avenue Paul Marcellin, 69120 Vaulx-en-Velin
Secteur d'activité	Bâtiment — Travaux Tous Corps d'État (TCE)
Période du stage	Du 06 avril 2026 au 29 mai 2026 (8 semaines)
Maître de stage	Christophe Gallifet — Directeur général
Tutrice enseignante	Isabelle Dautraix
Intitulé de la mission	Constitution d'une base de données articles fournitures par extraction automatisée de factures PDF
Technologies utilisées	Python, Azure Document Intelligence, API Groq (LLaMA3.3), Streamlit, Excel, Power Query, openpyxl, PyPDF2, pytesseract, OCRmyPDF, pdf2image
Lieu du stage	Locaux administratifs de Numérobis Rénovation, Vaulx-en-Velin
Encadrement et autonomie	Encadrement direct par le maître de stage ; autonomie complète sur les choix techniques
Ressources mises à disposition	Poste de travail, accès aux factures PDF, fichier Excel comptable, documentation interne
Objectif principal du stage	Automatiser l'extraction des articles des factures fournisseurs pour constituer une base de données exploitable

Remerciements

Je tiens à adresser mes sincères remerciements à Christophe Gallifet, mon maître de stage, pour m'avoir accordé sa confiance et une autonomie totale tout au long de ces huit semaines. Sa disponibilité lors de nos points hebdomadaires, ses retours constructifs, et sa pédagogie pour m'expliquer les processus métier de l'entreprise ont été essentiels à l'avancement de mes missions.

Je remercie également l'ensemble de l'équipe de Numérobis Rénovation pour l'accueil chaleureux qui m'a été réservé. Les échanges du quotidien, notamment lors des repas partagés avec les collaborateurs, ont été une source précieuse d'apprentissage sur la culture d'entreprise et le fonctionnement d'une PME du bâtiment.

Je remercie enfin Isabelle Dautraix, tutrice enseignante, pour son suivi pédagogique tout au long du stage, ainsi que l'ensemble des enseignants du département Informatique de l'IUT Lyon 1 dont les cours m'ont fourni les bases nécessaires pour mener à bien ces missions.

Sommaire

Introduction.....	6
Contexte et obtention du stage.....	6
Présentation de l'entreprise.....	6
Problématique et missions confiées.....	6
Annonce du plan.....	7
Partie 1 — Présentation de l'environnement du stage.....	8
1.1 L'entreprise Numérobis Rénovation.....	8
1.1.1 Historique et développement.....	8
1.1.2 Activités, marchés et qualifications.....	8
1.1.3 Ressources humaines.....	8
1.2 Organisation et place du stagiaire.....	9
1.2.1 Structure organisationnelle.....	9
1.2.2 Place du stagiaire dans l'organisation.....	9
1.2.3 Organisation du travail au quotidien.....	9
1.3 Contexte technologique et situation initiale des données.....	10
1.3.1 Environnement informatique de l'entreprise.....	10
1.3.2 Nature et hétérogénéité des factures.....	10
1.3.3 Le fichier Excel existant.....	10
Partie 2 — Présentation des missions.....	11
2.1 Vue d'ensemble et organisation des missions.....	11
2.1.2 Gestion de projet.....	11
2.2 Mission 1 — Recherche et évaluation des outils d'extraction.....	12
2.2.1 Analyse du besoin et choix du langage de développement.....	12
2.2.2 Phase de tests — les outils open source.....	12
2.2.3 Découverte et adoption d'Azure Document Intelligence.....	13
2.2.4 Le mécanisme de contrôle qualité.....	13
2.2.5 Conclusion de la phase de recherche.....	14
2.3 Mission 2 — Développement de l'application de saisie (Streamlit).....	14
2.3.1 Origine de la mission et expression du besoin.....	14
2.3.2 Architecture de l'application.....	15
2.3.3 Interruption et réorientation des priorités.....	15
2.4 Mission 3 — Extraction batch et construction de la base articles.....	16
2.4.1 Développement du script d'extraction batch.....	16
2.4.2 Les contraintes de l'API Groq et leur gestion.....	16
2.4.3 Résultats bruts de l'extraction.....	16
2.4.4 Nettoyage des données avec Power Query.....	17
2.4.5 Nettoyage des libellés et gestion des doublons.....	17
2.4.6 Enrichissement de la base avec des formules Excel.....	18
2.5 Livrable final et bilan des missions.....	18
Partie 3 — Bilan des compétences.....	19
3.1 Compétences techniques acquises et développées.....	19
3.1.1 Python : passage à un usage professionnel.....	19
3.1.2 Microsoft Excel et Power Query.....	19

3.1.3 Évaluation et sélection d'outils techniques.....	20
3.2 Compétences transversales.....	20
3.2.1 Communication avec un interlocuteur non technique.....	20
3.2.2 Autonomie et gestion du travail.....	21
3.2.3 Culture d'entreprise et intégration professionnelle.....	22
3.3 Lien avec la formation BUT Informatique.....	22
3.4 Bilan personnel et projet professionnel.....	23
Conclusion.....	24
Sources.....	25
Documentation technique.....	25
Sitographie.....	25
Formation et référentiels.....	25
Glossaire.....	26
Annexes.....	29
Annexe 1 – Organigramme de Numérobis Rénovation.....	29
Annexe 2 – Schéma d'architecture de l'extraction (Azure + Groq).....	29
Annexe 3 – Interface de l'application de saisie Streamlit.....	30
Annexe 4 – Nettoyage des données avec Power Query.....	31
Annexe 5 – Fichier Excel final (base articles).....	32
Annexe 6 – Gestion de projet - Kanban.....	33
Annexe 7 – Exemples de fichiers PDFs scannées.....	34

Introduction

Contexte et obtention du stage

Ce stage de huit semaines, réalisé du 6 avril au 29 mai 2026 au sein de la société Numérobis Rénovation à Vaulx-en-Velin, s'inscrit dans le cadre de la deuxième année du BUT Informatique. L'opportunité m'a été transmise par un camarade de classe qui m'a communiqué les coordonnées de Christophe Gallifet, directeur général de l'entreprise. Ce qui m'a immédiatement convaincu d'accepter ce stage, c'est la nature des missions proposées : un projet ouvert, sans solution imposée, nécessitant de trouver seul les outils adaptés et de construire une solution de bout en bout. Cette dimension fortement autonome correspondait exactement à ce que je souhaitais expérimenter.

Mes connaissances au départ étaient limitées sur les outils directement impliqués : des bases en Python, quelques notions de traitement de données acquises en cours, et une maîtrise basique d'Excel. J'avais en revanche des notions sur les API REST et les appels HTTP, abordés lors de SAE en deuxième année, ce qui allait s'avérer utile.

Présentation de l'entreprise

Numérobis Rénovation est une entreprise spécialisée dans les travaux de rénovation Tous Corps d'État (TCE), fondée en 2004 et basée au 117 avenue Paul Marcellin, 69120 Vaulx-en-Velin, dans l'agglomération lyonnaise. Elle intervient sur des chantiers de rénovation, de restructuration et d'aménagement de locaux à usage résidentiel, commercial et tertiaire, aussi bien pour des particuliers que pour des professionnels.

L'entreprise compte environ 24 collaborateurs et intervient sur l'ensemble des corps de métier d'un chantier : maçonnerie, plâtrerie, peinture, carrelage, plomberie, électricité et menuiserie. Elle est qualifiée RGE et QUALIBAT sur plusieurs domaines. Cette polyvalence lui permet d'assurer la maîtrise d'œuvre complète de ses chantiers sans sous-traiter les différents corps de métier.

Problématique et missions confiées

Numérobis Rénovation gère chaque année plusieurs milliers de factures d'achats fournisseurs. En 2025, ces 3 093 factures étaient stockées sous forme de fichiers PDF dans un répertoire organisé par mois, et le seul outil de suivi disponible était un fichier Excel contenant uniquement les totaux de chaque facture (montant HT, TVA,

TTC, nom du fournisseur). Aucune information sur les articles achetés — désignation, quantité, prix unitaire, fournisseur — n'était disponible de manière structurée et exploitable.

La mission qui m'a été confiée était d'extraire automatiquement le contenu de ces factures pour constituer une base de données articles fournitures permettant à l'entreprise de disposer d'une vision analytique de ses achats : quels articles sont achetés, à quels prix, chez quels fournisseurs, et comment ces prix évoluent dans le temps.

Avant le début du stage, mes attentes étaient orientées vers Excel : je souhaitais approfondir ma maîtrise de cet outil, découvrir le VBA et Power Query. La réalité des missions m'a conduit bien au-delà, vers le développement Python avancé, les API cloud, l'intelligence artificielle appliquée à la gestion documentaire, et finalement Power Query dans un contexte de traitement de données réelles à grande échelle.

Annonce du plan

Ce rapport s'articule en trois parties. La première présente l'environnement du stage: l'entreprise, son organisation, le contexte technologique et la situation initiale des données. La deuxième décrit en détail les trois missions réalisées : la phase de recherche et test des outils d'extraction, le développement d'une application de saisie assistée, et l'extraction batch complète suivie du nettoyage et de l'enrichissement de la base. La troisième partie dresse un bilan des compétences développées et des apports personnels et professionnels de cette expérience.

Partie 1 — Présentation de l'environnement du stage

1.1 L'entreprise Numérobis Rénovation

1.1.1 Historique et développement

Fondée en 2004 par ses deux associés gérants, Numérobis Rénovation a progressivement développé son activité dans le secteur de la rénovation en région lyonnaise. Cette croissance s'est traduite en 2017 par l'acquisition et la rénovation de nouveaux locaux permettant la fusion géographique des pôles Administratif et Production, ainsi que la création d'un espace showroom dédié à l'accueil et au conseil de la clientèle. La société est aujourd'hui un acteur reconnu de la rénovation TCE dans l'agglomération lyonnaise, intervenant sur des chantiers d'envergure variée pour une clientèle mixte de particuliers et de professionnels.

1.1.2 Activités, marchés et qualifications

La spécificité de Numérobis Rénovation réside dans son agrément Tous Corps d'État, qui lui permet d'intégrer en interne la maîtrise d'œuvre sur l'ensemble des lots d'un chantier. Cette organisation évite le recours à de multiples sous-traitants et garantit une cohérence d'exécution sur les chantiers. Les domaines d'intervention couvrent notamment la démolition et maçonnerie, la plâtrerie et peinture, les revêtements de sol, la menuiserie, le carrelage, la plomberie et l'électricité. L'entreprise est qualifiée RGE (Reconnu Garant de l'Environnement) et QUALIBAT sur plusieurs corps de métier, lui permettant d'intervenir sur des chantiers bénéficiant d'aides à la rénovation énergétique. Sa clientèle se compose de particuliers (rénovation de logements, appartements, maisons), de professionnels (bureaux, commerces, hôtels, salles de sport, établissements recevant du public) et de bailleurs sociaux, essentiellement dans l'agglomération lyonnaise.

1.1.3 Ressources humaines

L'entreprise compte environ 24 collaborateurs répartis en deux pôles distincts. Le pôle Administratif comprend les deux dirigeants associés, un responsable administratif et financier, des assistantes administratives et un chargé de clientèle. Le pôle Production regroupe les conducteurs de travaux et 16 techniciens salariés spécialisés dans les différents corps de métier, dont deux chefs de chantier chargés de la coordination sur site.

1.2 Organisation et place du stagiaire

1.2.1 Structure organisationnelle

L'équipe de Numérobis Rénovation est organisée autour d'une structure resserrée. L'entreprise est dirigée par ses deux associés gérants, Benjamin Léger et José Cafagna. La direction générale et la gestion administrative et financière sont assurées par Christophe Gallifet, secondé par Chrystel Chavant, assistante de direction. L'équipe comprend également un magasinier, Farès, chargé de la gestion des stocks et des approvisionnements, ainsi que plusieurs directeurs de travaux supervisant les chantiers en cours. L'ensemble du personnel administratif partage les mêmes locaux, ce qui favorise une communication directe et une prise de décision rapide. ([Annexe 1](#))

1.2.2 Place du stagiaire dans l'organisation

Rattaché à l'équipe administrative, j'ai travaillé sous la supervision directe de Christophe Gallifet, directeur général et maître de stage, qui constituait mon interlocuteur principal au quotidien. Il est important de souligner qu'il n'est pas informaticien : la nature de nos échanges a donc été dès le départ orientée vers la traduction des besoins métier en solutions techniques, et inversement.

La configuration de travail était particulière : j'étais seul sur la partie informatique, sans collègue développeur autour de moi. Chaque blocage technique nécessitait de trouver la solution de façon autonome, que ce soit via la documentation officielle, des forums spécialisés ou des vidéos de démonstration. Cette autonomie, si elle était parfois exigeante, a été l'un des apprentissages les plus formateurs du stage. Il est également utile de mentionner que le livrable final — la base articles Excel constituée à partir des factures extraites — sera utilisé en priorité par Farès, le magasinier, pour le suivi et la gestion des approvisionnements. Cela a influencé les choix de présentation et d'ergonomie du fichier Excel livré : lisibilité, clarté des colonnes, facilité de consultation sans compétence technique particulière

1.2.3 Organisation du travail au quotidien

Le rythme de travail s'organisait autour d'une grande liberté dans la gestion des journées. Après un cadrage initial des besoins avec Christophe Gallifet, je gérais librement l'avancement des missions, avec un point de suivi hebdomadaire pour présenter les résultats, ajuster les priorités et prendre les décisions techniques en commun.

Un aspect inattendu mais important du quotidien : les repas partagés avec les différents collaborateurs de l'entreprise — conducteurs de travaux, assistantes administratives, techniciens. Ces moments informels m'ont permis de comprendre le fonctionnement d'une PME du bâtiment au-delà de mon seul périmètre de travail, d'appréhender les enjeux métier, et de développer une aisance relationnelle en milieu professionnel que les projets académiques ne permettent pas d'acquérir.

1.3 Contexte technologique et situation initiale des données

1.3.1 Environnement informatique de l'entreprise

L'environnement informatique de Numérobis Rénovation était essentiellement bureautique. Le logiciel central utilisé pour le suivi comptable et financier était Microsoft Excel. Aucun ERP ou logiciel de gestion intégré n'était en place pour la gestion des achats fournisseurs. L'ensemble des factures d'achats était stocké sous forme de fichiers PDF dans un répertoire Windows organisé comme suit :

Un dossier racine : « Achats 2025 »

Des sous-dossiers par mois : « Janvier », « Février », ..., « Décembre »

Dans chaque sous-dossier : les fichiers PDF des factures du mois, nommés par leur numéro de facture

Cette organisation, bien que logique pour un archivage manuel, ne permettait aucune exploitation automatisée ou analytique du contenu des factures.

1.3.2 Nature et hétérogénéité des factures

La principale difficulté technique du projet tenait à la nature des documents à traiter. Les 3 093 factures présentaient les caractéristiques suivantes :

PDF scannés : la quasi-totalité des factures étaient des images numérisées, sans couche texte sélectionnable. Les outils de lecture de texte PDF classiques ne pouvaient donc pas fonctionner.

Mise en forme non standardisée : chaque fournisseur avait son propre format de facture. Certaines étaient sous forme de tableau structuré, d'autres en texte libre, avec des polices, des dispositions et des niveaux de qualité de scan très variables.

Qualité d'impression variable : certaines factures étaient de mauvaise qualité (scan de mauvaise résolution, texte penché, encre pâlie), rendant leur lecture difficile même pour un humain.

Contenu hétérogène : parmi les fichiers classés dans le dossier Achats 2025, toutes les factures n'étaient pas des factures de fournitures matières. Certaines concernaient des frais de stationnement (ANTAI), des frais de tenue de compte bancaire, des éco-contributions ou d'autres charges sans rapport avec les articles achetés. ([Annexes 7](#))

1.3.3 Le fichier Excel existant

L'entreprise disposait d'un fichier Excel de synthèse (« Synthèse 2025 ») contenant une ligne par facture avec les informations globales : numéro de facture, nom du fournisseur, montant HT, montant TVA, montant TTC, et référence de chantier. Ce fichier avait été constitué manuellement au fil de l'année et constituait la seule source d'information structurée disponible sur les achats de 2025.

Ce fichier était précieux car il permettait de croiser les résultats d'extraction avec les totaux connus, et de récupérer automatiquement le nom du fournisseur associé à chaque numéro de facture.

Partie 2 — Présentation des missions

2.1 Vue d'ensemble et organisation des missions

Les missions se sont enchaînées de manière itérative plutôt que linéaire. La mission initiale — l'extraction automatique des articles des factures — a généré en cours de route une mission dérivée (le développement d'une application de saisie), avant que les priorités ne reviennent au cœur du projet. Le déroulement chronologique peut être résumé ainsi :

Semaine	Période	Tâches principales
S1	06/04 → 12/04	Analyse du besoin, exploration des factures, choix du langage, premiers tests OCR
S2	13/04 → 19/04	Tests PyPDF2, pdf2image, pytesseract, OCRmyPDF ; comparaison des outils
S3	20/04 → 26/04	Découverte d'Azure Document Intelligence ; premiers essais ; validation technique
S4	27/04 → 03/05	Début du développement de l'application Streamlit (interface + logique)
S5	04/05 → 10/05	Suite du développement Streamlit ; gestion des champs ; tableau éditable
S6	11/05 → 17/05	Extraction batch des 3 093 factures ; mise en place du contrôle qualité ; fallback Groq
S7	18/05 → 24/05	Nettoyage Power Query ; suppression des doublons ; normalisation des libellés
S8	25/05 → 29/05	Enrichissement Excel ; finalisation de la base articles ; préparation des livrables

2.1.2 Gestion de projet

La gestion de ce projet a été organisée de manière itérative, proche d'une approche agile. Dès la première semaine, un cadrage initial a permis de définir les grandes étapes et les livrables attendus. Pour assurer un suivi quotidien et une visibilité claire sur l'avancement, j'ai utilisé un tableau Kanban sur Notion. Cet outil m'a permis de classer les tâches par statut (À faire, En cours, Terminé) et de prioriser les actions au fil des semaines, notamment lors des

réorientations comme l'interruption temporaire du développement de l'application Streamlit qui sera expliquée par la suite.

Le suivi global s'est articulé autour de points hebdomadaires avec Christophe Gallifet, mon maître de stage, afin de valider les orientations techniques, ajuster les priorités en fonction des résultats obtenus et prendre les décisions de réorientation. ([Annexe 6](#))

2.2 Mission 1 — Recherche et évaluation des outils d'extraction

2.2.1 Analyse du besoin et choix du langage de développement

La première semaine a été consacrée à la compréhension complète du contexte : exploration du répertoire Achats 2025, analyse des factures de différents fournisseurs, identification des structures de données à extraire (désignation, quantité, prix unitaire, montant HT) et évaluation de la difficulté du problème. Le choix de Python comme langage de développement s'est imposé naturellement pour trois raisons : c'est le langage qui dispose de l'écosystème le plus riche en bibliothèques de traitement documentaire et d'appel d'API, c'est celui que je maîtrisais le mieux, et c'est le langage recommandé par la majorité des ressources en ligne traitant de ce type de problème.

2.2.2 Phase de tests — les outils open source

Mes recherches sur YouTube et Reddit m'ont conduit à tester successivement plusieurs bibliothèques open source. Ces tests ont été réalisés sur un échantillon de factures de différents fournisseurs pour évaluer la fiabilité de chaque outil.

PyPDF2 a été le premier outil testé. Cette bibliothèque Python permet de lire le texte contenu dans des fichiers PDF. Elle s'est avérée immédiatement inutilisable dans notre contexte : les factures étant des PDFs scannés (images), elles ne contiennent aucune couche texte sélectionnable. PyPDF2 renvoyait des chaînes vides ou quelques métadonnées sans intérêt.

pdf2image a ensuite été utilisée pour convertir les pages PDF en images, comme étape de prétraitement avant l'application d'un OCR. L'outil fonctionnait correctement pour la conversion, mais ne réalisait pas lui-même la reconnaissance de caractères. pytesseract, l'interface Python pour le moteur OCR Tesseract de Google, a été testée sur les images produites par pdf2image. Les résultats étaient décevants : sur des factures de bonne qualité, le texte était partiellement reconnu, mais la structure tabulaire (colonnes désignation, quantité, prix) était systématiquement perdue. Sur les factures de moins bonne qualité ou présentant des mises en forme non standards, le taux d'erreur rendait les données inexploitable.

OCRmyPDF a été évalué comme alternative plus robuste à pytesseract. Cet outil ajoute une couche OCR à un PDF scanné pour le rendre recherachable. Bien que la qualité de reconnaissance soit légèrement supérieure, le problème de structuration des données restait entier : l'outil produisait du texte brut sans identification des champs (désignation, quantité, prix unitaire).

Les limitations observées étaient communes à tous ces outils open source : incapacité à comprendre la sémantique d'une facture, confusion entre les zones d'en-tête et les lignes articles, erreurs de lecture sur les chiffres (un 8 lu comme un 3, un 1 lu comme un l), et aucune gestion de la diversité des formats entre fournisseurs.

2.2.3 Découverte et adoption d'Azure Document Intelligence

C'est en visionnant des vidéos YouTube traitant de l'extraction d'informations depuis des PDFs scannés que j'ai découvert Azure Document Intelligence (anciennement Azure Form Recognizer), un service cloud Microsoft spécialisé dans l'analyse et la compréhension de documents. Ce service propose un modèle pré-entraîné spécifiquement pour les factures, appelé « prebuilt-invoice », capable d'identifier et d'extraire les champs structurés d'une facture quel que soit son format : numéro, date, fournisseur, lignes d'articles avec code produit, désignation, unité, quantité et montant HT.

La différence fondamentale avec les outils open source testés précédemment est que Azure Document Intelligence ne se contente pas de reconnaître des caractères : il comprend la structure sémantique du document. Il sait qu'une colonne de chiffres alignée à droite est probablement une colonne de prix, que le bloc en haut à gauche est probablement le fournisseur, que le tableau au centre contient les lignes articles. Cette intelligence documentaire est le fruit d'un entraînement sur des millions de factures réelles.

En complément, j'ai intégré l'API Groq comme solution de repli. Groq est un fournisseur d'inférence de grands modèles de langage (LLM), basé sur le modèle LLaMA 3.3 70B. Son avantage dans ce contexte est double : sa conformité RGPD (les données ne sont pas conservées pour l'entraînement) et sa rapidité d'inférence. Le principe retenu est le suivant : Azure traite chaque facture en premier ; si le résultat est jugé suspect par un contrôle qualité automatique, le texte extrait est transmis à Groq qui interprète les données via un prompt structuré et renvoie les lignes au format JSON. ([Annexe 2](#))

2.2.4 Le mécanisme de contrôle qualité

Pour détecter automatiquement les extractions défectueuses d'Azure et déclencher le fallback vers Groq, j'ai mis en place une fonction de contrôle qualité basée sur plusieurs indicateurs. Les tests réalisés sur l'échantillon de factures avaient révélé des anomalies récurrentes : des prix unitaires dépassant plusieurs milliers d'euros alors que le total TTC de la facture était inférieur à 100 euros, le nom de Numerobis

Rénovation (l'acheteur) identifié comme fournisseur, des lignes entièrement vides sans désignation ni montant, ou encore des montants identiques répétés sur de nombreuses lignes (signe que l'outil a lu le total en bas de page et l'a dupliqué). Le contrôle qualité vérifie ainsi trois critères principaux : la proportion de lignes sans libellé (si plus de 50% des lignes n'ont pas de désignation, le résultat est suspect), la présence de montants aberrants (seuil fixé à 100 000 € par ligne), et la répétition anormale d'un même montant sur plusieurs lignes (plus de 3 occurrences identiques). Si l'un de ces critères est déclenché, la facture bascule automatiquement vers le traitement Groq. ([Annexe 2](#))

2.2.5 Conclusion de la phase de recherche

Cette première mission s'est conclue par la validation de l'architecture hybride Azure + Groq sur un échantillon représentatif de factures. La robustesse du dispositif face à l'hétérogénéité des documents a été confirmée. Cette phase n'a pas abouti à une extraction complète : il s'agissait uniquement de valider la faisabilité technique avant d'investir dans le traitement des 3 093 documents.

2.3 Mission 2 — Développement de l'application de saisie (Streamlit)

2.3.1 Origine de la mission et expression du besoin

À l'issue de la phase de recherche, Christophe Gallifet a souhaité aller plus loin que la simple extraction batch des factures historiques. Il a exprimé le besoin de disposer d'un outil permettant de traiter les nouvelles factures au fil de l'eau, en s'appuyant sur l'extraction automatique tout en conservant la possibilité de corriger manuellement les champs incorrects avant l'enregistrement.

Cette expression de besoin a donné lieu à un exemple concret de la difficulté de communication entre un interlocuteur métier et un développeur. Lorsque Christophe m'a demandé de « pouvoir afficher les informations générales de la facture et les corriger », ma première réaction a été de lui demander s'il souhaitait des champs de type input ou du texte statique — une distinction technique évidente pour un développeur, mais totalement opaque pour quelqu'un qui n'a jamais programmé. Son incompréhension face à cette question m'a poussé à reformuler : « est-ce que tu veux pouvoir modifier ce que l'application a extrait, ou juste le voir ? » Cette reformulation en termes métier a immédiatement débloqué la conversation.

De même, lorsqu'il m'expliquait le processus de saisie des factures dans l'entreprise (vérification du fournisseur, du montant, attribution d'un compte comptable), je devais mentalement traduire ce flux métier en architecture applicative : écran de liste, écran de détail, formulaire d'édition, bouton de validation, écriture dans Excel. Ce travail de traduction permanent entre langage métier et langage technique a été l'un des apprentissages les plus significatifs de cette mission.

2.3.2 Architecture de l'application

J'ai développé l'application avec Streamlit, un framework Python open source qui permet de créer des interfaces web interactives sans développement front-end. Ce choix présentait plusieurs avantages : utilisation du même langage que les scripts d'extraction déjà développés, facilité d'intégration avec pandas et openpyxl pour la manipulation des fichiers Excel, et déploiement local sans serveur web dédié.

L'application se compose de deux écrans principaux. L'écran d'accueil permet le dépôt de fichiers PDF par glisser-déposer et le lancement de l'analyse. Une fois l'extraction réalisée, un tableau de synthèse affiche toutes les factures analysées avec leurs informations globales (fournisseur, date, montants HT/TVA/TTC, comptes comptables) et leur statut de vérification. L'écran de vérification affiche côte à côte le PDF original et les données extraites. L'utilisateur peut modifier tous les champs (fournisseur, date, référence chantier, montants, lignes articles) dans un tableau éditable, saisir les comptes comptables associés, puis valider pour enregistrer dans le fichier Excel de l'entreprise.

Des fonctionnalités complémentaires ont été intégrées : détection des doublons (vérification que le code facture n'est pas déjà présent dans la base avant traitement), génération d'un brouillard de saisie en PDF récapitulant les informations globales de la facture, et navigation entre les factures via une barre latérale indiquant le statut de vérification de chacune. ([Annexe 3](#))

2.3.3 Interruption et réorientation des priorités

L'application Streamlit a été développée jusqu'à un état fonctionnel dans ses grandes lignes, mais des ajustements restaient nécessaires pour la rendre pleinement utilisable en conditions réelles. Confronté à la contrainte de temps — il restait moins de trois semaines de stage — et en accord avec Christophe Gallifet, la décision a été prise de suspendre cette mission pour revenir à la priorité initiale : l'extraction complète des 3 093 factures historiques et la constitution de la base articles.

Cette décision illustre une réalité du monde professionnel que la formation académique n'anticipe pas toujours : il faut parfois savoir renoncer à une fonctionnalité élaborée pour garantir la livraison d'un livrable essentiel. L'application Streamlit a été laissée dans un état documenté, permettant une reprise ultérieure.

2.4 Mission 3 — Extraction batch et construction de la base articles

2.4.1 Développement du script d'extraction batch

Le script d'extraction batch (`extraction_batch.py`) a pour objectif de traiter automatiquement l'ensemble des 3 093 PDFs du répertoire Achats 2025 sans intervention manuelle. Il implémente l'architecture hybride Azure + Groq validée lors

de la phase de recherche, avec plusieurs mécanismes supplémentaires rendus nécessaires par le volume à traiter.

Le script commence par charger le fichier Excel de synthèse de l'entreprise pour disposer du nom du fournisseur et du total HT associé à chaque numéro de facture. Il parcourt ensuite les sous-dossiers mensuels dans l'ordre chronologique et traite chaque PDF selon la séquence suivante : appel à Azure Document Intelligence avec le modèle prebuilt-invoice, contrôle qualité du résultat, basculement vers Groq si nécessaire, puis écriture des lignes extraites dans le fichier Excel de sortie.

Un mécanisme de reprise automatique a été mis en place via un fichier texte (progression.txt) enregistrant le chemin de chaque facture traitée avec succès. En cas d'interruption — coupure réseau, limite d'API atteinte, erreur inattendue — le script peut être relancé et reprend automatiquement à partir de la dernière facture non traitée, sans retraiter les documents déjà complétés.

2.4.2 Les contraintes de l'API Groq et leur gestion

L'utilisation de l'API Groq dans sa version gratuite imposait une limite stricte : environ 150 à 200 factures traitables par clé API avant d'épuiser le quota de tokens disponibles (rate limit). Pour contourner cette contrainte sans engager de coûts, j'ai créé cinq comptes Groq distincts, chacun avec sa propre clé API. Lorsqu'une clé atteignait sa limite, le script s'arrêtait avec un message d'erreur explicite, et il suffisait de mettre à jour la clé dans le fichier de configuration pour reprendre le traitement. Ce fonctionnement explique pourquoi l'extraction complète des 3 093 factures a duré environ trois jours : les interruptions liées aux quotas d'API, bien que gérées proprement, imposent des pauses entre les sessions de traitement. Le traitement Azure, lui, n'impose pas ce type de limitation dans le cadre des crédits disponibles.

2.4.3 Résultats bruts de l'extraction

À l'issue des trois jours de traitement, le fichier Excel de sortie contenait l'ensemble des lignes articles extraites de l'année 2025. Chaque ligne comporte : le numéro de facture, le fournisseur, le code produit (quand disponible), la désignation de l'article, l'unité de mesure, la quantité, le prix unitaire calculé, le montant HT de la ligne, et le total HT de la facture source. Ces données brutes nécessitent cependant un travail important de nettoyage avant d'être exploitables.

2.4.4 Nettoyage des données avec Power Query

Le fichier brut issu de l'extraction contenait plusieurs catégories de données parasites qu'il fallait éliminer. J'ai utilisé Power Query, l'outil de transformation de données intégré à Microsoft Excel, pour réaliser ce nettoyage. L'avantage décisif de Power Query dans ce contexte est que les transformations sont enregistrées sous forme de requêtes applicables : les mêmes règles de nettoyage s'appliqueront automatiquement aux nouvelles données qui seront ajoutées à l'avenir (lors de

l'extraction des factures 2026, par exemple), sans avoir à refaire le travail manuellement.

Le nettoyage s'est déroulé en plusieurs étapes successives. La première consistait à supprimer les fournisseurs non pertinents : certains « fournisseurs » présents dans les données n'étaient pas des vendeurs d'articles mais des organismes émettant des factures de charges (ANTAI pour les contraventions de stationnement, la banque pour les frais de tenue de compte). Ces fournisseurs ont été entièrement exclus car aucune de leurs factures ne contenait d'articles matières.

La deuxième étape consistait à filtrer les lignes parasites au sein des factures de fournisseurs légitimes. Même chez des fournisseurs de matériaux, certaines lignes ne correspondent pas à des articles : les éco-contributions (taxes environnementales sur certains produits), les frais de port, les remises globales, et diverses charges annexes. Ces lignes ont été identifiées et supprimées par filtrage sur la désignation. La troisième étape concerne les avoirs : dans la comptabilité d'une entreprise, un avoir est un remboursement partiel ou total d'une facture, qui se traduit par des montants négatifs dans les données. Ces lignes ont été exclues de la base articles car elles ne correspondent pas à des achats réels et fausserait les calculs de prix moyens. ([Annexe 4](#))

2.4.5 Nettoyage des libellés et gestion des doublons

Un problème inattendu mais significatif est apparu lors de la phase de nettoyage : les désignations des articles extraites par l'IA contenaient de nombreuses imperfections dues à la variabilité des scans — retours à la ligne intempestifs dans le milieu d'un libellé, espaces surnuméraires, variations de casse, fragments de texte parasites issus de mauvaises reconnaissances OCR. Ces imperfections empêchaient la déduplication correcte des articles : un même produit pouvait apparaître sous deux libellés légèrement différents (un espace en plus, un retour à la ligne) et être traité comme deux articles distincts.

Un travail de nettoyage des libellés a donc été nécessaire : suppression des retours à la ligne dans les désignations, normalisation des espaces multiples, harmonisation de la casse. Ce nettoyage a été réalisé via des transformations Power Query. Une fois les libellés normalisés, la déduplication a pu être effectuée. Christophe Gallifet souhaitait disposer d'une vue consolidée de la base articles, avec chaque article représenté une seule fois, indépendamment du nombre de fois qu'il avait été acheté. La stratégie retenue a été de créer deux feuilles distinctes dans le fichier Excel : une feuille de détail conservant l'ensemble des occurrences (utile pour les analyses historiques et les calculs de prix), et une feuille articles sans doublon servant de référentiel des produits achetés.

2.4.6 Enrichissement de la base avec des formules Excel

La dernière étape du projet consistait à enrichir la base de données avec des indicateurs analytiques calculés à partir des données extraites. Pour chaque article

présent dans la feuille sans doublon, des formules Excel ont été créées pour agréger les données de la feuille de détail et calculer trois indicateurs de prix :

Le prix unitaire minimum (PU min) : prix le plus bas observé pour cet article sur l'ensemble des achats de l'année, permettant d'identifier le meilleur tarif obtenu et le fournisseur le plus compétitif.

Le prix unitaire maximum (PU max) : prix le plus élevé observé, permettant de détecter les achats au-dessus du marché ou les variations tarifaires anormales.

Le prix unitaire moyen (PU moyen) : moyenne arithmétique des prix d'achat sur la période, servant de référence pour les futurs devis et négociations fournisseurs.

Ces indicateurs constituent le cœur de la valeur ajoutée de la base articles pour l'entreprise. Christophe Gallifet peut désormais consulter, pour chaque article acheté en 2025, l'historique complet des prix et identifier immédiatement si un devis fournisseur est en ligne avec les prix habituellement pratiqués. ([Annexe 5](#))

2.5 Livrable final et bilan des missions

À la fin du stage, les livrables remis à l'entreprise comprennent : le fichier Excel de la base articles avec ses deux feuilles (détail complet et référentiel sans doublon) enrichies des indicateurs PU min/max/moyen ; le script Python d'extraction batch (extraction_batch.py) avec sa configuration et sa documentation, permettant d'étendre le traitement aux factures 2026 ; le pipeline Power Query enregistré dans le fichier Excel, applicable automatiquement aux nouvelles données ; et l'application Streamlit dans son état fonctionnel actuel. Deux points restent en suspens faute de temps : la finalisation de l'application Streamlit, qui nécessiterait encore quelques jours de développement et de tests pour être utilisable en production, et l'extraction des factures 2026.

Partie 3 — Bilan des compétences

3.1 Compétences techniques acquises et développées

3.1.1 Python : passage à un usage professionnel

Python est sans conteste la compétence technique sur laquelle ma progression a été la plus marquée. En arrivant, je maîtrisais les fondamentaux du langage (structures de données, fonctions, bibliothèques standard) sans expérience de projets complexes impliquant plusieurs modules, des appels d'API ou du traitement de données à grande échelle.

Au cours du stage, j'ai développé des compétences nouvelles sur plusieurs dimensions. La structuration d'un projet multi-fichiers avec séparation claire des responsabilités : le fichier d'extraction (`extract.py`), le fichier de configuration (`config.py`), le script batch (`extraction_batch.py`) et l'interface utilisateur (`app.py`) forment un ensemble cohérent et maintenable. L'intégration d'API cloud professionnelles via leurs SDK Python — Azure Document Intelligence et Groq — avec gestion des erreurs, des timeouts et des limites de quota. La robustesse industrielle d'un script de traitement en masse : gestion des exceptions, reprise sur incident, journalisation de la progression, validation des données en sortie. Et le développement d'une application web fonctionnelle avec Streamlit, incluant gestion d'état entre les pages, navigation, lecture et écriture de fichiers Excel.

Apprentissages critiques mobilisés : AC11.01 (implémenter des composants simples), AC11.03 (appliquer une conception), AC11.04 (développer des interfaces utilisateurs), AC21.01 (implémenter une application à partir d'exigences), AC21.04 (vérifier et valider la qualité par les tests).

3.1.2 Microsoft Excel et Power Query

Bien que mes attentes initiales portaient principalement sur Excel, la réalité du stage m'a conduit à utiliser cet outil dans un contexte bien plus exigeant que prévu. Power Query, que je ne connaissais pas avant le stage, s'est révélé un outil puissant pour le traitement de données volumineuses. J'ai appris à construire des pipelines de transformation réutilisables : filtrage multicritères, nettoyage de texte, suppression de doublons, jointures entre tables.

L'avantage fondamental de Power Query par rapport à un nettoyage manuel dans Excel est son caractère déclaratif et réapplicable : les transformations sont des étapes enregistrées qui s'appliquent automatiquement à chaque actualisation des données sources. Cette propriété est essentielle dans notre contexte, où les mêmes règles de nettoyage devront s'appliquer aux nouvelles données ajoutées en 2026. J'ai également développé des formules Excel avancées (MINIFS, MAXIFS, AVERAGEIFS) pour l'enrichissement de la base articles, en comprenant l'importance

de la structuration des données pour permettre ce type d'agrégations. Le VBA, initialement envisagé, n'a finalement pas été utilisé : Python et Power Query couvraient l'ensemble des besoins sans nécessiter de macros.

Apprentissages critiques mobilisés : AC13.03 (installer/configurer un service dans une architecture d'exploitation), AC14.01 (mettre à jour et interroger une base de données), AC24.01 (optimiser les modèles de données), AC24.02 (assurer l'intégrité et la sécurité des données).

3.1.3 Évaluation et sélection d'outils techniques

Une compétence transversale développée durant ce stage est la capacité à évaluer rapidement des outils techniques : identifier leurs cas d'usage, leurs limites, et décider rapidement de les adopter ou de les abandonner. La séquence PyPDF2 → pdf2image + pytesseract → OCRmyPDF → Azure Document Intelligence + Groq illustre cette démarche : chaque outil a été testé sur un échantillon représentatif avant d'être jugé adapté ou insuffisant. Cette approche itérative de test et de pivot, inspirée des méthodologies agiles, a permis d'éviter d'investir du temps dans des directions sans issue.

Les sources utilisées pour cette veille technologique — vidéos YouTube, discussions Reddit, documentation officielle Microsoft — ont été des compléments indispensables aux enseignements académiques, qui ne peuvent pas couvrir des technologies aussi récentes et spécialisées.

Apprentissages critiques mobilisés : AC12.01 (analyser un problème avec méthode), AC12.02 (comprendre des algorithmes classiques), AC22.03 (analyser/améliorer des structures de données et du code), AC22.04 (évaluer l'impact des solutions).

3.2 Compétences transversales

3.2.1 Communication avec un interlocuteur non technique

C'est probablement la compétence sur laquelle ma progression a été la plus inattendue et la plus significative. Travailler quotidiennement avec Christophe Gallifet, responsable administratif sans background informatique, m'a imposé de développer une double compétence : comprendre les besoins métier exprimés en langage non technique, et les reformuler en termes compréhensibles pour valider les choix de développement.

L'exemple de l'application Streamlit est révélateur de cette difficulté initiale. Ma première réponse à sa demande — « est-ce que tu veux des inputs ou du texte ? » — était une question technique sans sens pour lui. J'ai dû apprendre à reformuler en termes fonctionnels : « est-ce que tu veux pouvoir modifier ce que l'application a trouvé, ou juste le consulter ? ». De même, quand il m'expliquait le processus de

traitement des factures dans l'entreprise, je devais simultanément comprendre le flux métier et mentalement le traduire en architecture logicielle.

Les points hebdomadaires ont été un exercice régulier et exigeant de communication professionnelle. Il fallait expliquer pourquoi l'extraction avait pris trois jours (limites d'API, rotation de clés), pourquoi certaines factures étaient mal reconnues (qualité du scan, format non standard), pourquoi l'application Streamlit n'était pas finalisée et quelle était la stratégie pour la suite. Ces explications devaient être claires, concises et suffisamment précises pour que les décisions prises soient éclairées.

La formation du BUT Informatique m'avait fourni des bases théoriques sur la communication professionnelle en module dédié. La mise en situation concrète est cependant arrivée plus intensément et plus tôt que je ne l'anticipais. C'est en pratiquant semaine après semaine que j'ai progressivement trouvé le bon niveau de vulgarisation — ni trop simplifié au point d'être imprécis, ni trop technique au point d'être inaccessible.

Apprentissages critiques mobilisés : AC15.01 (appréhender les besoins du client), AC16.03 (identifier les rôles dans une équipe), AC28.03 (mobiliser ses compétences personnelles dans une équipe).

3.2.2 Autonomie et gestion du travail

L'absence de collègue développeur autour de moi a rendu l'autonomie non pas un objectif mais une nécessité. Chaque blocage technique — une bibliothèque qui ne fonctionne pas comme attendu, une API qui retourne des erreurs inattendues, un comportement étrange de Power Query — devait être résolu seul, en combinant documentation officielle, forums spécialisés (Stack Overflow, Reddit) et expérimentation directe.

Cette contrainte a développé une méthodologie de résolution de problèmes : identifier précisément le comportement observé, formuler une hypothèse sur la cause, tester cette hypothèse, interpréter le résultat, et itérer. Cette démarche systématique, qui s'applique aussi bien à un bug Python qu'à un résultat d'extraction inattendu, est une compétence professionnelle fondamentale que les projets académiques en groupe ne permettent pas de développer avec la même intensité.

Apprentissages critiques mobilisés : AC25.03 (suivre le déroulement d'un projet), AC35.01 (mesurer les impacts d'un projet), AC16.01 (appréhender l'écosystème numérique).

3.2.3 Culture d'entreprise et intégration professionnelle

Un facteur d'apprentissage que je n'avais pas anticipé a significativement enrichi ce stage : les repas quotidiens partagés avec les collaborateurs de Numérobis Rénovation. Ces moments informels — a priori anecdotiques — ont été une fenêtre précieuse sur le fonctionnement réel d'une PME du bâtiment : les enjeux d'un

chantier en retard, les relations avec les clients et les fournisseurs, les contraintes de planning et de main-d'œuvre, les décisions stratégiques.

Cette immersion dans la culture d'entreprise a eu un effet concret sur la qualité de mon travail : comprendre les enjeux métier de l'entreprise m'a permis de mieux prioriser les fonctionnalités à développer et de mieux adapter mes livrables aux besoins réels. Une base articles qui permet de comparer les prix fournisseurs a une valeur directement perceptible quand on a entendu les conducteurs de travaux parler de l'importance des marges sur les matériaux.

Apprentissages critiques mobilisés : AC16.01 (appréhender l'écosystème numérique), AC16.03 (identifier les rôles dans une équipe), AC28.03 (mobiliser ses compétences personnelles).

3.3 Lien avec la formation BUT Informatique

Plusieurs enseignements du BUT Informatique ont directement servi durant le stage. Les cours de Python et d'algorithmique ont fourni les bases sur lesquelles j'ai pu construire des scripts complexes. Les SAE impliquant des appels d'API REST m'ont préparé à l'intégration d'Azure Document Intelligence et de Groq. Les cours de gestion de données ont fourni les concepts (structuration, nettoyage, normalisation) mis en pratique avec Power Query.

En retour, le stage m'a apporté plusieurs dimensions que la formation n'avait pas encore eu l'occasion de couvrir. Le travail sur des volumes réels — 3 093 documents à traiter — confronté à des problèmes (gestion des erreurs, reprise sur incident, gestion des quotas d'API) que les projets académiques, de par leur taille limitée, ne font pas émerger. La robustesse industrielle d'un script de production n'est pas la même chose que la correction d'un programme de TD. Et surtout, la dimension relationnelle avec un client non-technique — traduire un besoin métier en solution informatique, et expliquer une solution informatique à un utilisateur métier — est une compétence que seule l'expérience professionnelle peut véritablement forger.

Apprentissages critiques mobilisés : ensemble des AC liés au développement, à la gestion et à l'exploitation des données (AC11 → AC35).

3.4 Bilan personnel et projet professionnel

Ce stage confirme et renforce mon orientation professionnelle vers l'analyse de données. Mes attentes initiales étaient orientées vers Excel et VBA — deux outils du monde des données mais dans leur dimension bureautique. La réalité du stage m'a emmené vers Python, les API cloud et l'IA appliquée à la gestion documentaire, un domaine à la frontière de l'informatique et de la data science.

Sur le plan des regrets, deux points ressortent. L'application Streamlit n'a pas pu être finalisée faute de temps, alors qu'elle représentait une valeur ajoutée réelle pour

l'entreprise. L'extraction des factures 2026 n'a pas pu être réalisée pour la même raison, même si les outils développés permettront de le faire facilement par la suite. Sur le plan des satisfactions, les livrables principaux ont été atteints : la base articles est constituée, nettoyée, enrichie d'indicateurs de prix et opérationnelle. L'entreprise dispose d'une vision analytique de ses achats qu'elle n'avait pas auparavant. Et sur le plan personnel, la progression en communication professionnelle est l'apport que j'estime le plus structurant pour la suite de mon parcours : dans le métier de data analyst que je vise, la capacité à comprendre un besoin client et à communiquer des résultats techniques à des interlocuteurs non-spécialistes est aussi importante que la maîtrise des outils.

Apprentissages critiques mobilisés : AC28.03 (mobiliser ses compétences personnelles), AC35.01 (mesurer les impacts d'un projet).

Conclusion

Ce stage au sein de Numérobis Rénovation a été une expérience singulière et formatrice, dont la réalité a largement dépassé les attentes initiales. Parti avec l'objectif d'approfondir Excel et de découvrir VBA, j'ai finalement construit de bout en bout un système complet d'extraction automatique de données documentaires, mobilisant Python, des services cloud d'intelligence artificielle et des outils de traitement de données avancés.

La problématique de départ était ambitieuse : extraire automatiquement et de façon fiable le contenu de 3 093 factures scannées, hétérogènes, issues de dizaines de fournisseurs différents, pour constituer une base articles exploitable. La solution mise en place — une architecture hybride combinant Azure Document Intelligence pour la reconnaissance documentaire et Groq comme intelligence artificielle de secours — a permis de relever ce défi. Le livrable principal, une base articles structurée avec des indicateurs de prix (minimum, maximum, moyen) par article, représente une valeur concrète et immédiatement utilisable pour l'entreprise.

Au-delà du livrable technique, ce stage a été l'occasion de développer des compétences que la formation académique prépare théoriquement mais que seule l'expérience professionnelle permet d'ancrer réellement. La communication avec un interlocuteur non-informaticien — apprendre à formuler des questions techniques en termes métier, à vulgariser des choix d'architecture, à présenter un avancement hebdomadaire de façon claire et actionnable — s'est révélée aussi exigeante et aussi formatrice que les défis techniques eux-mêmes.

Ce stage confirme mon projet professionnel dans le domaine de l'analyse de données. Il m'a convaincu que la valeur d'un data analyst ne réside pas uniquement dans sa maîtrise des outils techniques, mais dans sa capacité à faire le lien entre un besoin métier et une solution informatique — à comprendre ce qu'une entreprise cherche à savoir sur ses données, et à lui apporter une réponse exploitable. C'est cette double compétence, technique et relationnelle, que je souhaite continuer à développer dans la suite de mon parcours.

Sources

Documentation technique

Microsoft Azure Document Intelligence — Documentation officielle du modèle prebuilt-invoice :

<https://learn.microsoft.com/fr-fr/azure/ai-services/document-intelligence/>

Groq API — Documentation officielle et guide de démarrage :

<https://console.groq.com/docs>

Streamlit — Documentation officielle :

<https://docs.streamlit.io>

Python openpyxl — Documentation :

<https://openpyxl.readthedocs.io>

pytesseract — Interface Python pour Tesseract OCR :

<https://github.com/madmaze/pytesseract>

OCRmyPDF — Documentation officielle :

<https://ocrmypdf.readthedocs.io>

pdf2image — Documentation :

<https://github.com/Belval/pdf2image>

Microsoft Power Query — Documentation officielle :

<https://learn.microsoft.com/fr-fr/power-query/>

Sitographie

Numerobis Rénovation — Site de l'entreprise d'accueil :

<https://www.numerobis.pro>

Formation et référentiels

Ministère de l'Enseignement Supérieur et de la Recherche, *Référentiel national du BUT Informatique*, 2022.

Glossaire

API (Application Programming Interface) : Interface de programmation permettant à deux logiciels de communiquer entre eux via des requêtes standardisées. Dans ce stage, les API d'Azure Document Intelligence et de Groq ont été utilisées pour envoyer des documents à analyser et recevoir les données extraites en retour.

Azure Document Intelligence : Service cloud Microsoft basé sur l'intelligence artificielle, spécialisé dans l'analyse et l'extraction d'informations structurées depuis des documents (factures, formulaires, reçus). Le modèle « prebuilt-invoice » utilisé dans ce stage a été entraîné sur des millions de factures réelles et est capable d'identifier les champs d'une facture quel que soit son format.

Avoir : En comptabilité, document émis par un fournisseur pour rembourser partiellement ou totalement une facture (retour de marchandise, erreur de facturation). Dans les données extraites, les avoirs se traduisent par des montants négatifs.

Éco-contribution : Taxe environnementale incluse dans le prix de certains produits, destinée à financer leur recyclage en fin de vie. Ces lignes apparaissaient dans les factures de fournitures mais ne correspondent pas à des articles achetés.

Fallback : Mécanisme de secours qui prend le relais lorsqu'une solution principale échoue ou retourne des résultats insuffisants. Dans ce stage, Groq joue le rôle de fallback par rapport à Azure Document Intelligence.

Groq : Fournisseur d'infrastructure d'inférence de grands modèles de langage (LLM), notable pour sa rapidité d'exécution. Dans ce stage, le modèle LLaMA 3.3 70B de Meta est utilisé via l'API Groq comme intelligence artificielle de secours pour interpréter le contenu textuel des factures.

LLM (Large Language Model) : Grand modèle de langage, un type de modèle d'intelligence artificielle entraîné sur de très grands corpus de texte et capable de comprendre et générer du langage naturel. LLaMA 3.3 70B (Meta) est le LLM utilisé dans ce stage via l'API Groq.

OCR (Optical Character Recognition) : Reconnaissance optique de caractères. Technologie permettant de convertir une image contenant du texte (scan, photo) en texte numérique éditible et sélectionnable.

OCRmyPDF : Outil open source qui ajoute une couche OCR aux fichiers PDF scannés pour les rendre recherchables. Testé et abandonné dans ce stage en raison de résultats insuffisants sur des factures hétérogènes.

pdf2image : Bibliothèque Python permettant de convertir les pages d'un fichier PDF en images (format PNG ou JPEG), utilisable comme étape de prétraitement avant l'application d'un OCR.

PDF image / PDF scanné : Fichier PDF dont le contenu est une image numérisée d'un document papier, sans couche texte sélectionnable. S'oppose au PDF natif (généré directement par un logiciel) dans lequel le texte est directement sélectionnable.

Power Query : Outil de transformation et de nettoyage de données intégré à Microsoft Excel (et Power BI). Il permet de définir des étapes de transformation qui s'appliquent automatiquement à chaque actualisation des données sources, sans manipulation manuelle répétée.

Prix unitaire (PU) : Prix d'une unité d'un article. Le PU min est le prix le plus bas observé pour un article sur la période, le PU max le plus élevé, et le PU moyen la moyenne arithmétique des prix d'achat.

PyPDF2 : Bibliothèque Python permettant de lire et manipuler des fichiers PDF natifs (extraction de texte, fusion de fichiers). Inutilisable sur les PDFs scannés qui ne contiennent pas de couche texte.

pytesseract : Interface Python pour le moteur OCR Tesseract, développé initialement par HP et maintenu par Google. Permet de reconnaître du texte dans des images. Testé et abandonné dans ce stage en raison d'une qualité insuffisante sur des factures hétérogènes.

Rate limit (limite de quota) : Restriction imposée par un fournisseur d'API sur le nombre de requêtes ou la quantité de données traitables sur une période donnée. L'API Groq gratuite impose une limite en nombre de tokens (unités de texte), atteinte après 150 à 200 factures traitées par clé API.

RGPD (Règlement Général sur la Protection des Données) : Règlement européen (2018) encadrant le traitement des données personnelles. Dans ce stage, le choix de Groq a notamment été motivé par sa conformité RGPD (les données soumises via l'API ne sont pas conservées à des fins d'entraînement).

SDK (Software Development Kit) : Kit de développement logiciel fourni par un éditeur pour faciliter l'intégration de ses services dans un programme. Azure et Groq fournissent tous deux des SDK Python.


Streamlit : Framework Python open source permettant de créer rapidement des applications web interactives orientées données, sans nécessiter de compétences en développement front-end (HTML, CSS, JavaScript).

TCE (Tous Corps d'État) : Désigne une entreprise du bâtiment capable d'intervenir sur l'ensemble des corps de métier d'un chantier (gros œuvre, second œuvre, finitions, équipements techniques) sans avoir recours à des sous-traitants pour chaque spécialité.


Token : En traitement du langage naturel, unité élémentaire de texte utilisée par les modèles de langage (approximativement équivalente à un mot ou une syllabe). Les quotas des API de LLM sont généralement exprimés en nombre de tokens traités par unité de temps.

Annexes

Annexe 1 – Organigramme de Numérobis Rénovation



Annexe 2 – Schéma d'architecture de l'extraction (Azure + Groq)



Annexe 3 – Interface de l’application de saisie Streamlit

Navigation

Accueil

Factures analysées

F2508001 (700.0 €)

Vérification des Factures

Sélection des factures PDF

Glissez vos PDF ici

F2508001.pdf 351.8KB

Lancer l'analyse

1 facture(s) analysée(s)

Facture	Fournisseur	Date	Réf. Chantier	HT (€)	TVA (€)	TTC (€)	Cpte Tiers	Cpte TVA	Cpte Charge
F2508001		2025-08-26		700.00	0.00	700.00	401	4456	60

Vérifier

Imprimer


Supprimer

Walid Babouri - Rapport de stage BUT Informatique - Numerobis Renovation

Annexe 5 – Fichier Excel final (base articles)

E2														=MIN(SI(ENSI/Extraction appurée'(G6';Extraction appurée'(B8:B82;Extraction appurée'(G6';>0"))													
		A		B		C		D		E		F		G		H											
	Code produit	Libellé	Catégorie fournisseur	Fournisseur	Unité	PU min	PU max	PU pondéré																			
1	2100150	WEBER, SYS PROTECT 20KG	Carreleur	LA PLATFROME VAUX-EN-VELIN	PCE	122,00	122,00	122,00																			
2	0620001	PROFIL RECULAV ARGT 3M P/O,90-95		FOUSIER	P	16,78	16,78	16,78																			
3	061810	CALCOT TALATYNE 20x100MM		TOLLINS	RL	9,52	11,90	11,11																			
4	100153	WEBER, PRIN UNIVERSL 3KG	Carreleur	LA PLATFROME VAISE, LA PLATFROME VAUX-EN-VELIN	PCE	58,40	64,90	63,82																			
5	100203	CHEVILLE A FRAPPER 6X55MM POUR MATERIAUX PEINS - 100 PIECES	Outilage & protection	LA PLATFROME VAUX-EN-VELIN	PCE	8,90	8,90	8,90																			
6	100318	COUDE MALE FEMELLE 45 DC 14 SAGET DE 2 PIECES	PloMBERIE	LA PLATFROME VENISIEUX	SAC	3,65	3,65	3,65																			
7	100420	RECEVEUR DALVO 120080CM ARDOISE BLANC	Santitaire	LA PLATFROME VAUX-EN-VELIN	PCE	289,00	289,00	289,00																			
8	100422	RECEVEUR DALVO 160080CM ARDOISE BLANC	Santitaire	LA PLATFROME VAUX-EN-VELIN	PCE	355,00	355,00	355,00																			
9	100423	RECEVEUR DALVO 90080CM ARDOISE BLANC	Santitaire	LA PLATFROME VENISIEUX	PCE	215,00	215,00	215,00																			
10	100425	RECEVEUR DALVO 140090CM ARDOISE BLANC	Santitaire	LA PLATFROME VAISE	PCE	375,00	375,00	375,00																			
11	100426	RECEVEUR DALVO 160090CM ARDOISE BLANC	Santitaire	LA PLATFROME VAUX-EN-VELIN	PCE	69,00	69,00	69,00																			
12	101487	CABLE ETHERNET CATEGORIE 6 OHMS FTP BLEU COUPJONNE DE 100 M	Electricien	LA PLATFROME VAISE	PCE	156,00	156,00	156,00																			
13	101492	ENSEMBLE DE DOUCHE DE RENOVATION PRIMERA	Santitaire	LA PLATFROME VAUX-EN-VELIN	PCE	19,00	19,00	19,00																			
14	101500	MITIGEUR LAVABO PRIMERA CHROME CARTOUCHE D 40 MM	Santitaire	LA PLATFROME VAUX-EN-VELIN	PCE	64,00	64,00	64,00																			
15	101513	ABATTANT SLIM DALVO STANDARD 45, 5 X 35,5 X 6/2,5 CM	Santitaire	LA PLATFROME VAUX-EN-VELIN	PCE	240,00	240,00	240,00																			
16	101833	ENSEMBLE LOPIGNA 80 CM LAQUE BLANC	Santitaire	LA PLATFROME VAISE, LA PLATFROME VAUX-EN-VELIN	PCE	250,00	250,00	250,00																			
17	101834	ENSEMBLE LOPIGNA 80 CM CHENE NATUREL	Santitaire	LA PLATFROME VAISE, LA PLATFROME VAUX-EN-VELIN	PCE	280,00	280,00	280,00																			
18	101835	LOT DE 2 PIEDS 35 CM	Santitaire	LA PLATFROME VAUX-EN-VELIN	PCE	19,20	19,20	19,20																			
19	101839	ECROU HU ACIER ZINGUE DIAMETRE 6 BOTE DE 500 PIECES	Outilage & protection	LA PLATFROME VAUX-EN-VELIN	BOI	10,25	10,25	10,25																			
20	101712	COFFRET DE CONSUMABLES POUR OUTILS OSCILLANTS	Outilage & protection	LA PLATFROME VAISE, LA PLATFROME VAUX-EN-VELIN	PCE	59,90	59,90	59,90																			
21	101731	COUDE DE RACCORDEMENT	Santitaire	LA PLATFROME VAISE	PCE	26,40	26,40	26,40																			
22	101805	MITIGEUR MONOTROU LAVABO MEZZO 3 CHROME	Santitaire	LA PLATFROME VAUX-EN-VELIN	PCE	35,50	35,50	35,50																			
23	101830	MITIGEUR MURAL BAIN/DOUCHE MEZZO 3 CHROME	Santitaire	LA PLATFROME VAUX-EN-VELIN	PCE	33,00	33,94	33,47																			
24	101831	MITIGEUR MURAL BAIN/DOUCHE MEZZO 3 CHROME	Santitaire	LA PLATFROME VAISE, LA PLATFROME VAUX-EN-VELIN	PCE	40,50	40,50	40,50																			
25	101833	LOT BATTI SUPPORT DUOFLY AUTOPORTANT ET CUVETTE DALVO STANDARD	Santitaire	LA PLATFROME VAUX-EN-VELIN	LOT	423,70	423,70	423,70																			
26	102066	PAIX WC PATIO SANS BRIDE SORTIE VERTICALE ABAISSANT FDC BLANC	Santitaire	LA PLATFROME VAUX-EN-VELIN	PCE	209,00	209,00	209,00																			
27	102069	LATEX PRET A L'EMPLOI SIMALTEX 360 2 L	Maçon	LA PLATFROME VAUX-EN-VELIN	BID	26,95	27,45	27,23																			
28	102227	ADOFFIT POUR BETON ET MORTIER SIMALTEX 360 5 L	Maçon	LA PLATFROME VAUX-EN-VELIN	BID	45,25	45,25	45,25																			
29	102228	CYNDRE ISIF 40x40	Outilage & protection	LA PLATFROME VAUX-EN-VELIN	PCE	8,05	8,05	8,05																			
30	10238	CYNDRE ISIF 60x60	Outilage & protection	LA PLATFROME VAUX-EN-VELIN	PCE	27,50	27,50	27,50																			
31	102410	CYNDRE DEBAYABLE ISIF 30x30	Menuisier Serrurier	LA PLATFROME VAUX-EN-VELIN	PCE	46,50	46,50	46,50																			
32	102411	CYNDRE DEBAYABLE ISIF 30x40	Menuisier Serrurier	LA PLATFROME VAUX-EN-VELIN	PCE	37,10	37,10	37,10																			
33	102414	VIS ROCKET 3 X 40 BOTE DE 500 PIECES	Outilage & protection	LA PLATFROME VAISE, LA PLATFROME VAUX-EN-VELIN, LA PLATFROME VAUX-EN-VELIN	BOI	13,60	13,60	13,60																			
34	10242	VIS ROCKET 4 X 40 BOTE DE 500 PIECES	Outilage & protection	LA PLATFROME VAISE, LA PLATFROME VAUX-EN-VELIN, LA PLATFROME VAUX-EN-VELIN	BOI	15,15	15,15	15,15																			
35	10247	ENSEMBLE PALIERE ALU ARGENT REVERSIBLE PERCAGE CYLINDRE	Outilage & protection	LA PLATFROME VAISE, LA PLATFROME VAUX-EN-VELIN, LA PLATFROME VAUX-EN-VELIN	BOI	16,20	16,20	16,20																			
36	10248	ENSEMBLE PALIERE ALU ARGENT REVERSIBLE PERCAGE CYLINDRE	Menuisier Serrurier	LA PLATFROME VENISIEUX	PCE	29,50	29,50	29,50																			
37	102485	2 CARRES A GONCE 7X130 MM ECHANGE DES 2 COTES	Menuisier Serrurier	LA PLATFROME VAISE	PCE	3,90	3,90	3,90																			
38	102488	VIS BOIS ROCKET POZI 5X60 35 MM 200 PIECES	Outilage & protection	LA PLATFROME VAUX-EN-VELIN	PCE	3,90	3,90	3,90																			
39	10280	VIS ROCKET TETE RAUSE POZ BICHROMATE 650MM BOTE DE 200 PIECES	Outilage & protection	LA PLATFROME VENISIEUX	BOI	15,25	15,25	15,25																			
40	10283	VIS ROCKET TETE RAUSE POZ BICHROMATE 650MM BOTE DE 200 PIECES	Outilage & protection	LA PLATFROME VAISE	BOI	16,25	16,25	16,25																			
41	10284	VIS BOIS ROCKET POZI 16x60 35 BOTE DE 200	Outilage & protection	LA PLATFROME VENISIEUX	BOI	20,05	20,05	20,05																			
42	10284	VIS BETON ROUX HUSSEIN 7 X 160 50 PIECES	Outilage & protection	LA PLATFROME VENISIEUX	BOI	39,75	39,75	39,75																			
43	103147	SERRURE MULTI-USAGES	Menuisier Serrurier	LA PLATFROME VAUX-EN-VELIN	PCE	11,60	11,60	11,60																			
Extraction nouvelle base d'articles																											
		Extraction nouvelle		Extraction stable																							

Annexe 6 – Gestion de projet - Kanban



Annexe 7 – Exemples de fichiers PDFs scannées

REÇU

Le 13 JAN. 2025

**LA PLATEFORME
DU BATIMENT**

GAGNEZ DU TEMPS ET DE L'ARGENT



IMMEUBLE "LE MAGELLAN" 7, RUE BENJAMIN CONSTANT - 75927 PARIS CEDEX 19
S.A.S. AU CAPITAL DE 39 750 000 € - SIRET 403 104 250 - RCS PARIS - APE 4673 A
Numéro d'identification Intracommunautaire : FR B5 403104250

FACTURE 1713809/14-12-2024

ADRESSE DE LIVRAISON:
NUMEROBIS RENOVATION ACO
31 RUE CLAUDE BOYER
69007 LYON 07
DATE DE LIVRAISON 13-12-2024

NUMEROBIS RENOVATION ACO
NUMEROBIS RENOVATION ACO
117 AVENUE PAUL MARCELLIN
69120 VAULX EN VELIN

7850/084

03014579 Caisse:

Affaire traitée par LA PLATEFORME DU BÂTIMENT de : LYON 2
23, RUE MARIUS CROISSO.

69120 VAULX EN VELIN

Téléphone : 04.37.62.21.00 Fax : 04.72.02.07.07 SMS: 07.10.10.10.20 03-01-2025

Page:1

VOTRE REFERENCE: C202419357

CODE	DÉSIGNATION	QUANTITÉ	UNITÉ	PRIX H.T. UNITAIRE	MONTANT TOTAL H.T.	T.V.A.
BON DE COMMANDE : 141533 vd:Megane B. Titulaire:02 CAPAGNA JOSE						
32594	CHEVRON 90X110MM 4M CHX2	7.00	PCE	20.46	143.36	1
147417	ECO-PART VALOBAT PCMB 030301400	0.28	PCE	5.45	1.53	1
	Descript.: VALOBAT 0303014					
108705	LIVRAISON MOINS 3H INF 600 KG	1.00	PCE	78.33	78.33	1
(Montant Total HT Eco-Contribution PCMB : 1.53)						
					TOTAL HT	223.22 EUR
1 REGLEMENT A ECHEANCE: 45J FDM				Code Tx TVA 1 20.00	Base HT 223.22	44.64
					TOTAL TTC	267.86 EUR

TVA ACQUITTÉE SUR LES DÉBITES

Pénalités de retard: A compter du jour suivant la date limite de paiement : Taux d'intérêt légal majoré de 10 points.

Une indemnité forfaitaire pour frais de recouvrement de 40 Euros sera d'ye par le débiteur en retard.

02 31050 850 00/8



LA PLATEFORME DU BÂTIMENT - UNE MARQUE DE SAINT-GOBAIN

(voir conditions générales de vente sur notre site)
laplateforme.com

ORANGE FIXE BOX TV ⁶²⁶⁰⁰⁰
(04 38 84 27 55)

20/01/2025	84,00 €	F2501140
20/02/2025	84,00 €	
20/03/2025	84,00 €	
20/04/2025	84,00 €	
20/05/2025	84,00 €	
20/06/2025	84,00 €	
20/07/2025	84,00 €	
20/08/2025	84,00 €	
20/09/2025	84,00 €	
20/10/2025	84,00 €	
20/11/2025	84,00 €	
20/12/2025	84,00 €	

ORANGE FIXE ALARME ⁶²⁶⁰⁰⁰
(04 37 26 96 34)

20/01/2025	68,76 €	F2501141
20/02/2025		
20/03/2025	68,76 €	
20/04/2025		
20/05/2025	74,76 €	
20/06/2025		
20/07/2025	74,76 €	
20/08/2025		
20/09/2025	74,76 €	
20/10/2025		
20/11/2025	74,76 €	
20/12/2025		

JALIS ⁶¹⁵⁰⁰³
NUMEROBIS

15/01/2025	570,00 €	F2501142
15/02/2025	570,00 €	
15/03/2025	570,00 €	
15/04/2025	570,00 €	
15/05/2025	570,00 €	
15/06/2025	570,00 €	
15/07/2025	570,00 €	
15/08/2025	570,00 €	
15/09/2025	570,00 €	
15/10/2025	570,00 €	
15/11/2025	570,00 €	
15/12/2025	570,00 €	

APPLE - I TUNES JC ⁶²⁶⁰⁰⁰
Paiement via CB JC (pas de facture)

23/01/2025	2,99 €	F2501143
23/02/2025	2,99 €	
23/03/2025	2,99 €	
23/04/2025	2,99 €	
23/05/2025	2,99 €	
23/06/2025	2,99 €	
23/07/2025	2,99 €	
23/08/2025	2,99 €	
23/09/2025	2,99 €	
23/10/2025	2,99 €	
23/11/2025	2,99 €	
23/12/2025	2,99 €	

APPLE - I TUNES ME
Paiement via CB ME (pas de facture)

25/01/2025	9,99 €	F2501144
25/02/2025	9,99 €	
25/03/2025	9,99 €	
25/04/2025	9,99 €	
25/05/2025	9,99 €	
25/06/2025	9,99 €	
25/07/2025	9,99 €	
25/08/2025	9,99 €	
25/09/2025	9,99 €	
25/10/2025	9,99 €	
25/11/2025	9,99 €	
25/12/2025	9,99 €	

APPLE - I TUNES ME
Paiement via CB ME (pas de facture)

28/01/2025	2,99 €	F2501145
28/02/2025	2,99 €	
28/03/2025	2,99 €	
28/04/2025	2,99 €	
28/05/2025	2,99 €	
28/06/2025	2,99 €	
28/07/2025	2,99 €	
28/08/2025	2,99 €	
28/09/2025	2,99 €	
28/10/2025	2,99 €	
28/11/2025	2,99 €	
28/12/2025	2,99 €	